Apprentissage automatique supervisé

Rappels

Brice Chardin

2023–2024

API et nomenclature scikit-learn

API scikit-learn

Prédicteur

- `fit(X, y)` : entraine le modèle (détermine les valeurs des paramètres)
- `predict(X)` $\rightarrow \hat{y}$: infère les sorties associées à `X`

Transformateur

- `fit(X[, y])` : entraine le transformateur (détermine les valeurs des paramètres)
- `transform(X)` $\rightarrow$ `X'` : applique la transformation à `X`

Processus sans pipeline

Régression après deux transformations successives

```
1 tr1, tr2, reg = SimpleImputer(), MinMaxScaler(),
     LinearRegression()
2 # training
3 tr1.fit(X_train)
4 tr2.fit(tr1.transform(X_train))
5 reg.fit(tr2.transform(tr1.transform(X_train)), y_train)
6 # testing
7 reg.predict(tr2.transform(tr1.transform(X_test)))
```

→ Définir à la place un prédicteur complet comme une séquence de traitements (un *pipeline*)

Avec pipeline

Régression après deux transformations successives

```
pipe = Pipeline([
    # step name, transformator or predictor
    ("imputer", SimpleImputer()),
    ("normalizer", MinMaxScaler()),
    ("regressor", LinearRegression()),
])
# training
pipe.fit(X_train)
# testing
pipe.predict(X_test)
```

Pipelines

Pipelines avec N transformateurs $\rightarrow$ pipelines de transformation (`fit` et `transform`)

Pipelines avec N transformateurs et 1 prédicteur (classificateur ou regresseur) $\rightarrow$ pipelines de prédiction (`fit` et `predict`)

Transformations spécifiques à des colonnes

`ColumnTransformer`

```
1 tr = ColumnTransformer([
2     # step name, transformator, column(s)
3     ("scaling", StandardScaler(), ["year"]),
4     ("categories", OneHotEncoder(), ["origin", "location
        ", "ingredients"]),
5     ("passthrough", "passthrough", ["percent"]),
6 ])
```

- `passthrough` → continuer sans transformation
- Quelques (rares) transformateurs attendant des vecteurs 1D, il faudra leur fournir une colonne (`"year"`) et non une liste de colonnes (`["year"]`)
- Un pipeline de transformation peut être utilisé comme transformateur

Validation de modèles

Validation des modèles de régression

$$\textit{Mean absolute error}\ (\text{MAE}) = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

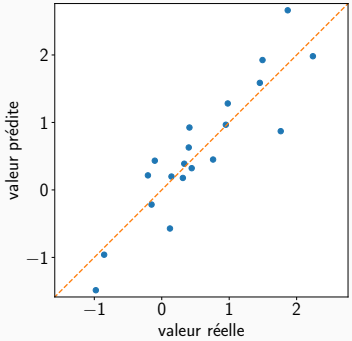
$$\textit{Root mean square error}\ (\text{RMSE}) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$$\text{Coefficient de détermination } R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y}_i)^2}$$

Et autres mesures qui peuvent dépendre des besoins applicatifs :

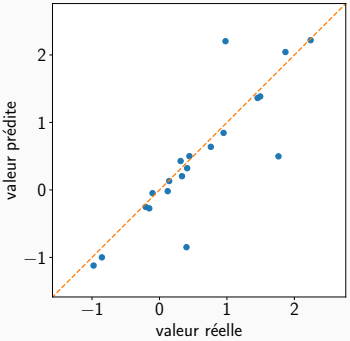
- *mean absolute percentage error* (MAPE)
- plus grande sous-estimation
- plus grande sur-estimation
- biais (tendance à sur- ou sous-estimer)
- etc.

Validation des modèles de régression



MAE : 0.33

RMSE : **0.42**



MAE : **0.27**

RMSE : 0.49

Validation des modèles de classification binaire

Exemple d'application en maintenance prédictive (100 observations)

Prédicteur idéal

	Défaillance prédite	
Défaillance réelle	**Vrai**	**Faux**
Vrai	3	0
Faux	0	97

Prédicteur aléatoire

	Défaillance prédite	
Défaillance réelle	**Vrai**	**Faux**
Vrai	2	1
Faux	46	51

Prédicteur de classe majoritaire

	Défaillance prédite	
Défaillance réelle	**Vrai**	**Faux**
Vrai	0	3
Faux	0	97

Autre prédicteur

	Défaillance prédite	
Défaillance réelle	**Vrai**	**Faux**
Vrai	2	1
Faux	8	89

Validation des modèles de classification binaire

Matrice de confusion

		Classe prédite
Classe réelle	**Vrai**	**Faux**
Vrai	TP	FN
Faux	FP	TN

- TP : True Positive (vrai positif) ← bien prédit
- TN : True Negative (vrai négatif) ← bien prédit
- FP : False Positive (faux positif) ← mal prédit
- FN : False Negative (faux négatif) ← mal prédit

Validation des modèles de classification binaire

Matrice de confusion

		Classe prédite
Classe réelle	**Vrai**	**Faux**
Vrai	TP	FN
Faux	FP	TN

- TP : True Positive (vrai positif) ← bien prédit
- TN : True Negative (vrai négatif) ← bien prédit
- FP : False Positive (faux positif) ← mal prédit
- FN : False Negative (faux négatif) ← mal prédit

$$\textbf{précision} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}}$$

$$\textbf{rappel} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}$$

$$\textbf{spécificité} = \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FP}}$$

$$\textbf{exactitude (accuracy)} = \frac{\mathrm{TP}+\mathrm{TN}}{\mathrm{TP}+\mathrm{TN}+\mathrm{FP}+\mathrm{FN}}$$

$$\textbf{balanced accuracy (BA)} = \frac{\text{rappel} + \text{spécificité}}{2}$$

$$\textbf{F1-score} = \frac{2 \times \text{précision} \times \text{rappel}}{\text{précision} + \text{rappel}}$$

Validation des modèles de classification binaire

	Classe prédite	
Classe réelle	**Vrai**	**Faux**
Vrai	2	1
Faux	8	89

$$\text{précision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{2}{2+8} = 20\% \rightarrow \text{défaillances prédites souvent fausses}$$

Validation des modèles de classification binaire

	Classe prédite	
Classe réelle	**Vrai**	**Faux**
Vrai	2	1
Faux	8	89

$$\text{précision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{2}{2+8} = 20\% \rightarrow \text{défaillances prédites souvent fausses}$$

$$\text{rappel} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{2}{2+1} = 66.7\% \rightarrow \text{pièces défaillantes parfois classées } \textit{non défaillantes}$$

Validation des modèles de classification binaire

	Classe prédite	
Classe réelle	**Vrai**	**Faux**
Vrai	2	1
Faux	8	89

$$\text{précision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{2}{2+8} = 20\% \rightarrow \text{défaillances prédites souvent fausses}$$

$$\text{rappel} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{2}{2+1} = 66.7\% \rightarrow \text{pièces défaillantes parfois classées } \textit{non défaillantes}$$

$$\text{spécificité} = \frac{\text{TN}}{\text{TN} + \text{FP}} = \frac{89}{89+8} = 91.2\% \rightarrow \text{pièces non défaillantes rarement classées défaillantes}$$

Validation des modèles de classification binaire

Mesures de qualité globales

Prédicteur idéal

Défaillance réelle	Défaillance prédite : Vrai	Défaillance prédite : Faux
Vrai	3	0
Faux	0	97

Exactitude : 100%
BA : 100%
F1 : 100%

Prédicteur aléatoire

Défaillance réelle	Défaillance prédite : Vrai	Défaillance prédite : Faux
Vrai	2	1
Faux	46	51

Exactitude : 53%
BA : 59.6%
F1 : 7.8%

Prédicteur de classe majoritaire

Défaillance réelle	Défaillance prédite : Vrai	Défaillance prédite : Faux
Vrai	0	3
Faux	0	97

Exactitude : 97%
BA : 50%
F1 : 0%

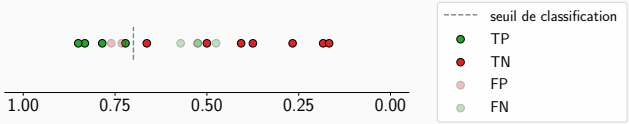
Autre prédicteur

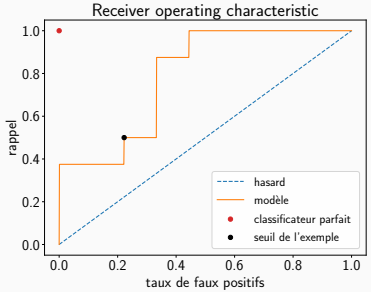
Défaillance réelle	Défaillance prédite : Vrai	Défaillance prédite : Faux
Vrai	2	1
Faux	8	89

Exactitude : 91%
BA : 79.2%
F1 : 30.8%

Courbe ROC

Ajustement du seuil de classification





Seuil à gauche de la courbe : classification à 100% dans la classe rouge (négatif)

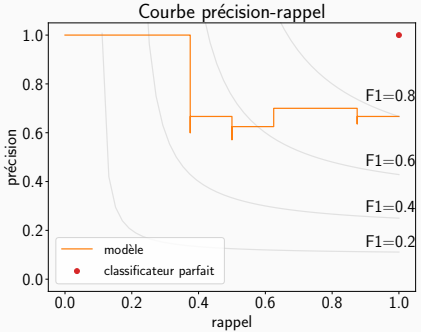
Seuil à droite de la courbe : classification à 100% dans la classe verte (positif)

Mesure de qualité globale : aire sous la courbe (AUC, *Area Under the Curve*)

Taux de faux positifs : $\frac{\mathrm{FP}}{\mathrm{FP}+\mathrm{TN}}$

Courbe précision-rappel

Ajustement du seuil de classification



À gauche de la courbe : classification à 100% dans la classe rouge (négatif)

À droite de la courbe : meilleure classification pour laquelle le rappel vaut 1

Validation des modèles avec classes multiples

Matrice de confusion

	Classe prédite		
Classe réelle	**A**	**B**	**C**
A	15	7	10
B	12	20	5
C	3	2	3

exactitude :

$$\frac{\text{nb éléments bien classés}}{\text{nb éléments total}} = \frac{15 + 20 + 3}{77} = 49.4\%$$

Validation des modèles avec classes multiples

Matrice de confusion

	Classe prédite		
Classe réelle	**A**	**B**	**C**
A	15	7	10
B	12	20	5
C	3	2	3

Correspondance avec une classification binaire :

$\mathrm{TP}(\mathrm{A}) = 15$

$\mathrm{FP}(\mathrm{A}) = 12 + 3 = 15$

$\mathrm{FN}(\mathrm{A}) = 7 + 10 = 17$

$\mathrm{TN}(\mathrm{A}) = 20 + 2 + 5 + 3 = 30$

$$\text{rappel}(\mathrm{A}) = \frac{\mathrm{TP}(\mathrm{A})}{\mathrm{TP}(\mathrm{A}) + \mathrm{FN}(\mathrm{A})} = \frac{15}{15 + 17} = 46.9\%$$

Validation des modèles avec classes multiples

Matrice de confusion

	Classe prédite		
Classe réelle	**A**	**B**	**C**
A	15	7	10
B	12	20	5
C	3	2	3

Correspondance avec une classification binaire :

$\mathrm{TP}(\mathrm{A}) = 15$

$\mathrm{FP}(\mathrm{A}) = 12 + 3 = 15$

$\mathrm{FN}(\mathrm{A}) = 7 + 10 = 17$

$\mathrm{TN}(\mathrm{A}) = 20 + 2 + 5 + 3 = 30$

$$\mathrm{rappel}(\mathrm{A}) = \frac{\mathrm{TP}(\mathrm{A})}{\mathrm{TP}(\mathrm{A}) + \mathrm{FN}(\mathrm{A})} = \frac{15}{15 + 17} = 46.9\%$$

Mesures globales : moyenne des scores de chaque classe

- mesures non pondérés (poids égaux)
- mesures pondérés par le nombre d'instances réelles

Validation des modèles avec classes multiples

$$\textbf{rappel} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}} \qquad \textbf{spécificité} = \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FP}}$$

En classification binaire, rappel(P) = spécificité(N) (et inversement)

→ balanced accuracy : moyenne des scores de rappel pour chaque classe

Matrice de confusion

		Classe prédite	
Classe réelle	**A**	**B**	**C**
A	15	7	10
B	12	20	5
C	3	2	3

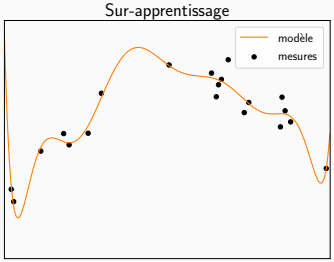
balanced-accuracy (moyenne des rappels) :

$$\frac{1}{3}\left(\frac{15}{15+7+10}+\frac{20}{12+20+5}+\frac{3}{3+2+3}\right)$$

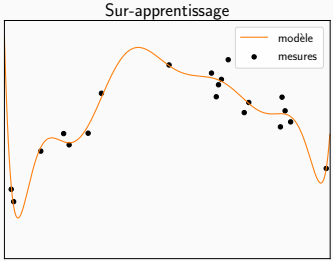
$$\frac{1}{3}(0.469+0.541+0.375) = 46.1\%$$

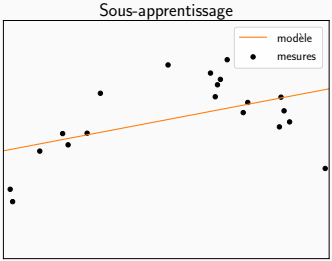
Méthodologie de validation

Sur- et sous-apprentissage

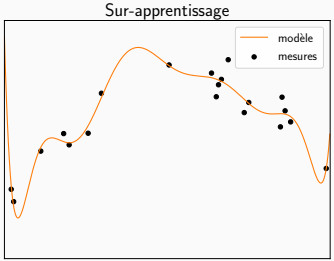


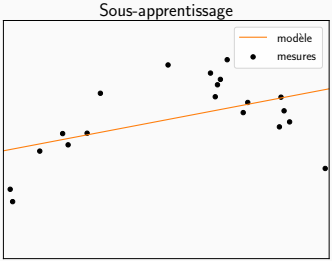
Sur- et sous-apprentissage

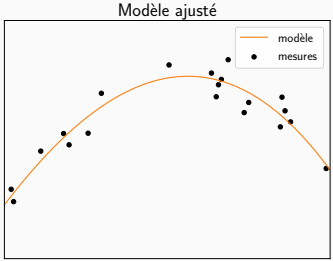




Sur- et sous-apprentissage







Méthodologie de validation



Mélange et séparation des données en deux ensembles :

- entraînement ($\sim 80\%$)
- test ($\sim 20\%$)



Évaluation du modèle sur les données de test n'ayant *jamais* été vues par celui-ci

$\rightarrow$ Estimation des performances réelles

Validation croisée

Résultats de validation pouvant varier significativement selon le découpage

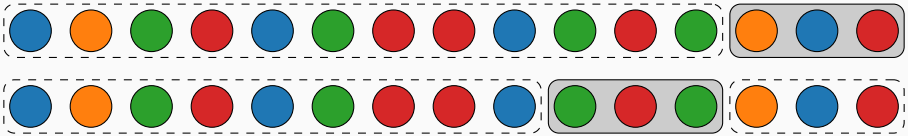
Principe : réaliser plusieurs découpages sur lesquels réaliser l'entraînement puis la validation, pour calculer une précision moyenne globale



Validation croisée

Résultats de validation pouvant varier significativement selon le découpage

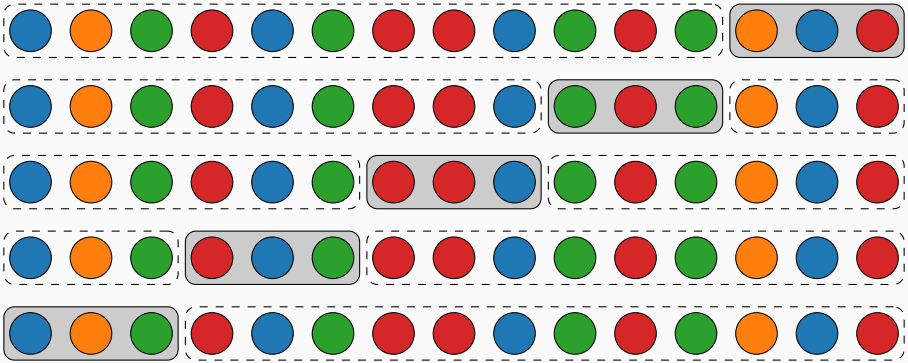
Principe : réaliser plusieurs découpages sur lesquels réaliser l'entraînement puis la validation, pour calculer une précision moyenne globale



Validation croisée

Résultats de validation pouvant varier significativement selon le découpage

Principe : réaliser plusieurs découpages sur lesquels réaliser l'entraînement puis la validation, pour calculer une précision moyenne globale



Validation croisée

Leave one out : $n - 1$ données d'entraînement, 1 donnée de test

Leave p out : $n - p$ données d'entraînement, p données de test

$\rightarrow$ explosion combinatoire : $\binom{n}{p}$ découpages

k-plis (*k-fold*)

- mélange des données
- définition de k partitions
- utilisation de $k - 1$ partitions pour l'entraînement et une partition pour le test

Validation croisée

Avantage : liste de scores et non score unique $\rightarrow$ étude de la variance du modèle

Méthodologie communément recommandée : k-plis (temps de calcul, pertinence)

Variantes de k-plis existantes pour :

- équilibrer les classes dans les plis générés
- équilibrer des groupes de données arbitraires
- traiter des séries temporelles

Optimisation des hyper-paramètres

Pour les modèles paramétrés (la plupart)

Méthodologie :

- définir une fonction de score pour comparer objectivement les résultats
- fixer l'espace de recherche des paramètres
- définir trois ensembles : entraînement, validation et test

→ Score obtenu sur les données de validation détermine les paramètres optimaux

Optimisation des hyper-paramètres

Pour les modèles paramétrés (la plupart)

Méthodologie :

- définir une fonction de score pour comparer objectivement les résultats
- fixer l'espace de recherche des paramètres
- définir trois ensembles : entraînement, validation et test

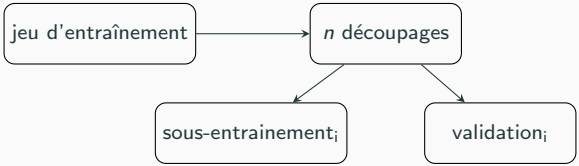
→ Score obtenu sur les données de validation détermine les paramètres optimaux

Nested cross-validation : k-plis imbriqués pour entraînement, validation et test

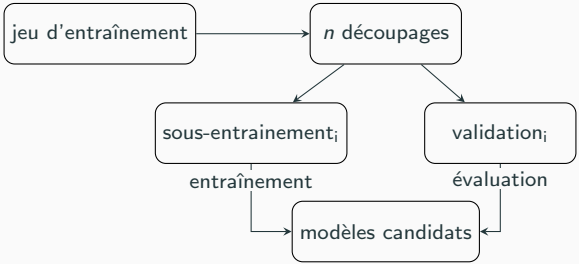
Entraînement avec optimisation des hyper-paramètres

jeu d'entraînement

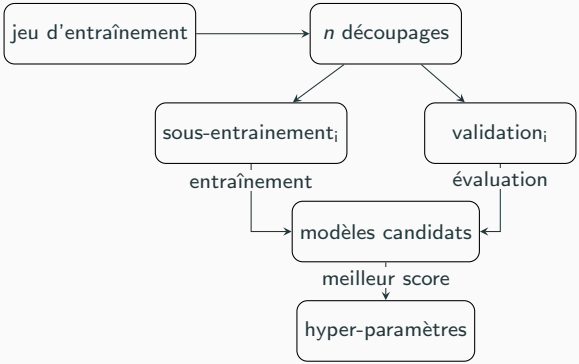
Entraînement avec optimisation des hyper-paramètres



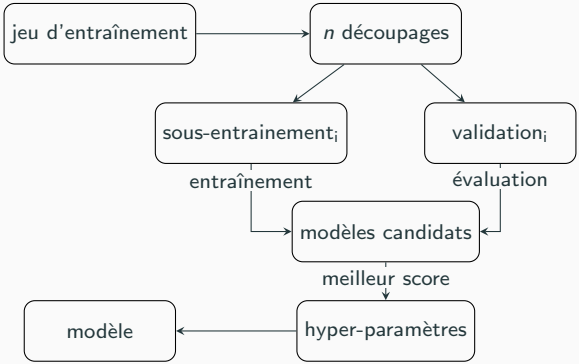
Entraînement avec optimisation des hyper-paramètres



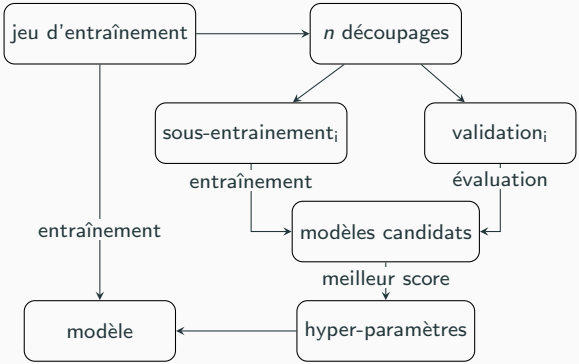
Entraînement avec optimisation des hyper-paramètres



Entraînement avec optimisation des hyper-paramètres



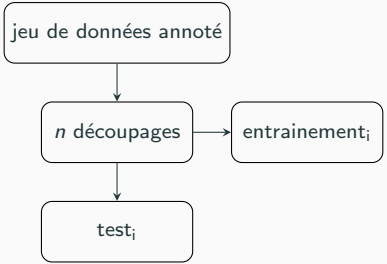
Entraînement avec optimisation des hyper-paramètres



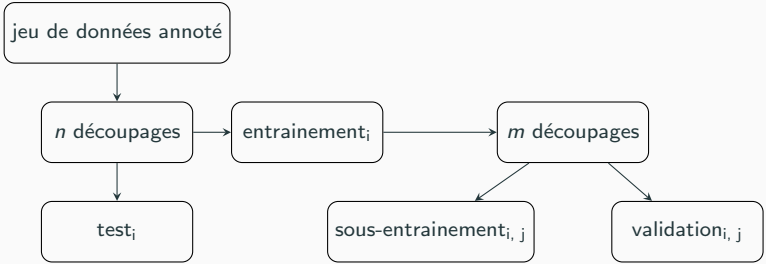
Méthodologie globale

jeu de données annoté

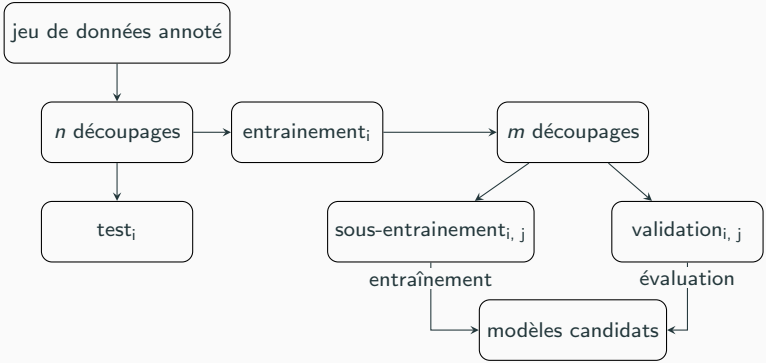
Méthodologie globale



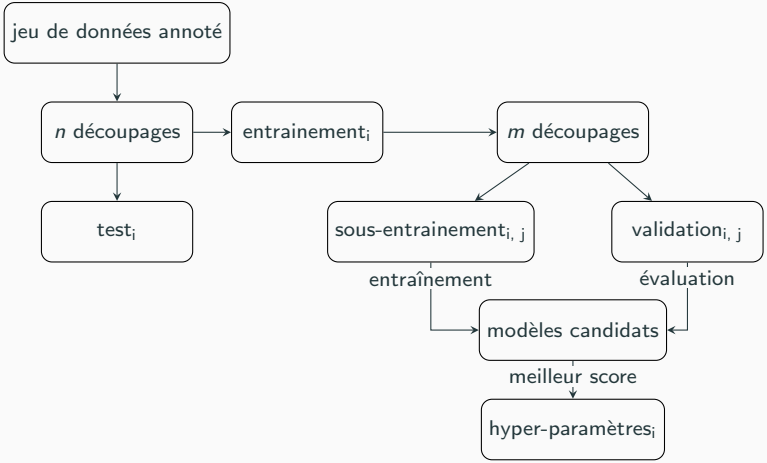
Méthodologie globale



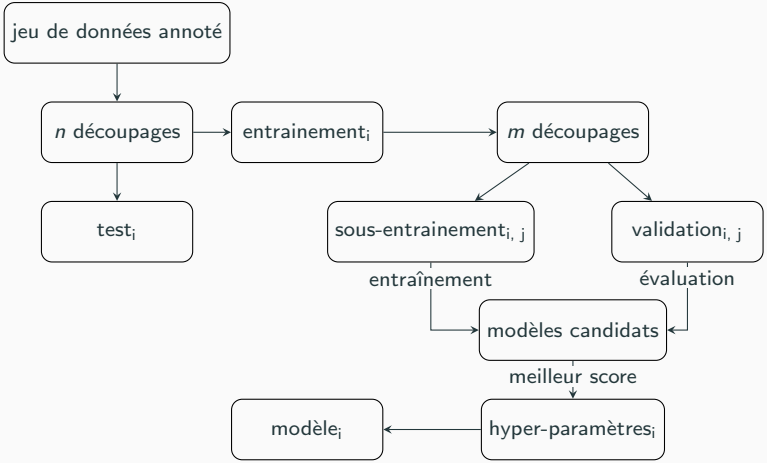
Méthodologie globale



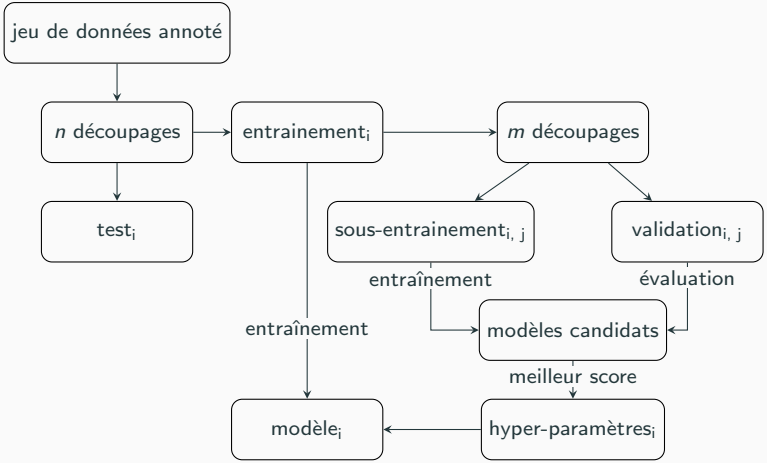
Méthodologie globale



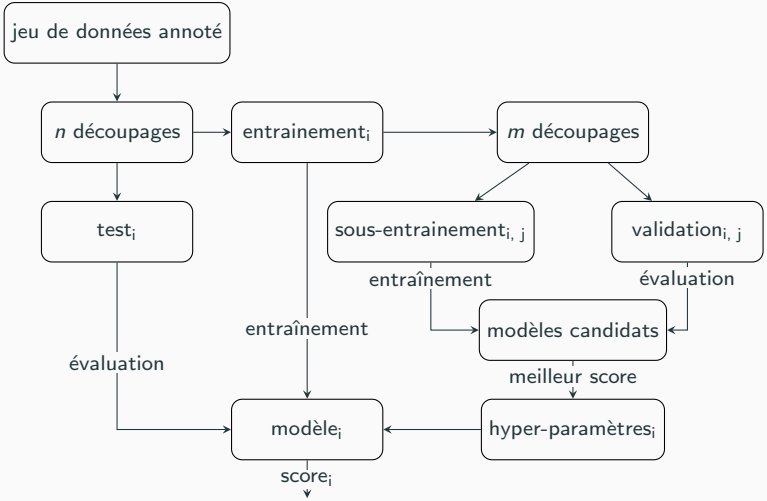
Méthodologie globale



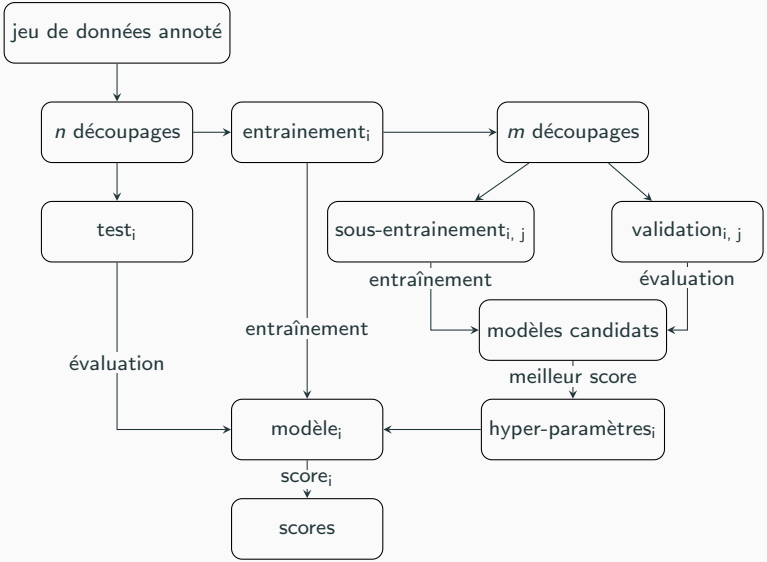
Méthodologie globale



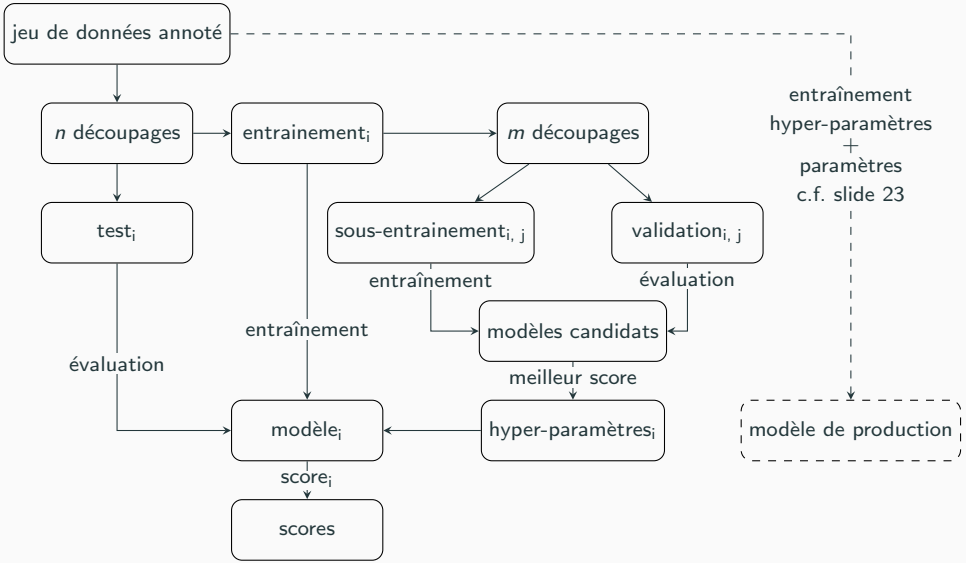
Méthodologie globale



Méthodologie globale



Méthodologie globale



Équilibrage des classes

Certain modèles sont sensibles à l'équilibre des classes

Sous-échantillonnage : supprimer des données sur-représentées

Sur-échantillonnage : générer de données d'entraînement supplémentaires

Génération de données

Compenser des classes sous représentées

Augmenter le jeu de données à moindre coût

Quelques stratégies (peuvent dépendre des données) :

- ajouter du bruit
- combiner linéairement des valeurs proches (SMOTE [1])
  e.g. ($x_1 \sim x_2$ et $y_1 \sim y_2$) donne $x_3 = \alpha x_1 + (1-\alpha)x_2$ et $y_3 = \alpha y_1 + (1-\alpha)y_2$
- appliquer des similitudes (rotation, translation, symétries, homothéties), en particulier sur des images

1. Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall and W. Philip Kegelmeyer. *SMOTE : synthetic minority over-sampling technique.* Journal of artificial intelligence research 16 (2002) : 321-357.

Inspection

Interprétation

Certains modèles intègrent de l'explicabilité (arbres de décision, modèles linéaires)

2. Christoph Molnar. Interpretable machine learning. 2021. https://christophm.github.io/interpretable-ml-book/

Interprétation

Certains modèles intègrent de l'explicabilité (arbres de décision, modèles linéaires)

Pour les autres : calculer la contribution de chaque caractéristique sur la prédiction

E.g. SHAP (SHapley Additive exPlanations) [2]

Principe général : remplacer aléatoirement une ou plusieurs valeurs par d'autres (piochées dans les données), et observer l'effet de ce remplacement sur la valeur prédite
Répéter l'opération jusqu'à convergence

2. Christoph Molnar. Interpretable machine learning. 2021. https://christophm.github.io/interpretable-ml-book/